Bedrägeridetektering

för Marketplace Safety

Ansvarsområden

Data & EDA - Victoria
Pipeline & preprocessing - Elisabeth
Modelljämförelse - Victoria
Optimering - Anarkoli
Threshold - Elisea
Modellutvärdering på testdata - Daniel
Pitch & risker - Daniel

Företaget · Problemet · Kravkort (Stakeholder)

Företaget

- Digital marknadsplats
- Köp & sälj mellan privatpersoner
- Högt transaktionsflöde dagligen

Problemet

- Misstänkta transaktioner flaggas
- Legitima användare störs i onödan
- Kundtjänst (Lina) får klagomålen

Kravkortet - Customer Support

- **Minimera onödiga flaggningar**
- Flaggningar ska kännas rimliga
- Rapportera till Lina, Customer Support

Data-insikter & EDA

12 000
rader

18
kolumner

10,2%
target (is_suspicious)

Saknade värden

price (818), time_to_first_response_min (590), region (340)
Numeriska ⟶ median
kategoriska ⟶ egen kategori.

Korrelationsmatris

Ingen enskild feature har stark linjär relation med target

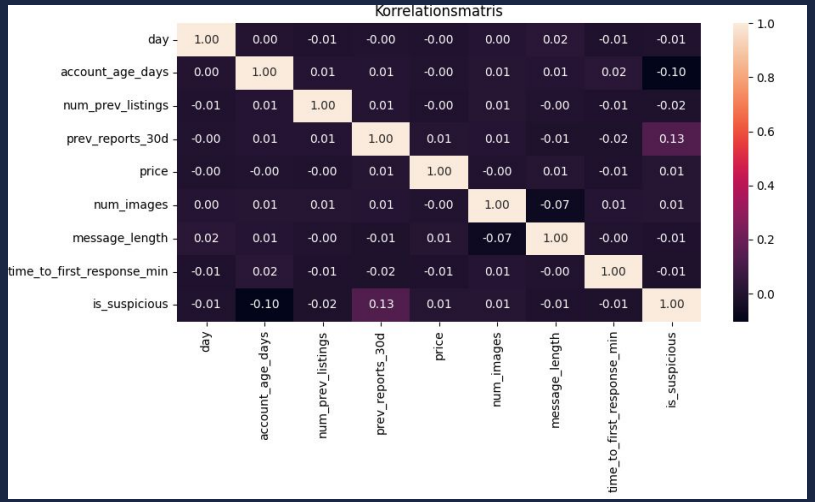

prev_reports_30d

Enda signalen.
Violinplot visar att is_suspicious-gruppen har fler tidigare rapporter.

Pipeline & undvika leakage

1

Train/Test Split

80% träning · 20% test
stratify=y (10% obalans)
random_state för reproducerbarhet

2

Preprocessing

Numeriskt:
median imputer - fylla i saknade värden
StandardScaler - normaliserar skalan

Kategoriskt:
constant imputer - “missing” blir egen kategori
OneHotEncoder - gör kategoriska värden till siffror

3

Pipeline

Tar numerisk pipeline och kategorisk pipeline separat

ColumnTransformer kombinerar de två pipelines

4

CV – StratifiedKFold

5 folds
shuffle=True
testdata rörs inte under träning

Pipeline-objektet stoppas in i CV-loopen, vilket gör att `fit()` på preprocessingen alltid sker inuti varje fold – aldrig på testdata

Modelljämförelse

Modell	Accuracy	Precision (CV)	Recall	F1
DummyClassifier (Baseline)	0.815	0.095	0.095	0.095
Random Forest	0.898	0.475	0.021	0.041
Logistic Regression	**0.899**	**0.602**	**0.045**	**0.083**

Varför Logistic Regression?

Högst Precision → minimerar onödiga flaggningar (Linas krav)
Enkel & tolkningsbar → flaggningar känns rimliga och konsekventa

Vald modell & hyperparameter-tuning

GridSearchCV – Logistic Regression

C
Startade med ett mycket bredare intervall och minskade det genom testning
Regulariseringsstyrka: lågt C = försiktig

class_weight None

None: modellen följer 90/10 fördelningen
(jämför Balanced som skulle ge is_suspicious = 1 mer vikt)

Scoring `precision`

Kopplat till kravkortet (minimera FP)

CV `StratifiedKFol`

Bibehåller klassfördelning

Bästa Parametrar

C	**0.03**
class_weight	**None**
CV Precision	**0.679**

Modellen är konservativ – undviker aggressiv flaggning

Threshold · Prioritering · Konsekvenser

Threshold	Flaggade	Precision	Recall	FP	FN
0.3	312	0.449	0.143	172	839
0.4	103	0.573	0.060	44	920
0.5	47	0.638	0.031	17	949
0.6	**19**	**0.684**	**0.013**	**6**	**966**
0.7	3	0.667	0.002	1	977

Precisionen på 0.40 på testdatan är mycket lägre än på träningsdatan. Det beror på att med endast 5 flaggade fall så har varje FP en stor påverkan på precision. Recall är mycket lågt (0.008) så de flesta verkliga bedrägerierna flaggas inte men vi har prioriterat precision utifrån vårt Kravkort.

Träningsdata, threshold 0.6

Flaggade: 19 av 9 600 (0.2%)
Precision: 0.684
13 TP - verkliga bedrägerier hittas
6 FP – Lina hanterar 6 ärenden
966 FN – missade bedrägerier

Testdata (20%)

Flaggade: 5 av 2 400 (0.2%)
Precision: 0.40
2 TP - verkliga bedrägerier hittas
3 FP – Lina hanterar 3 ärenden
243 FN – missade bedrägerier

Prediktion på ny data

new_data.csv läsdes in

Strategi:

- Threshold: 0.6
- Bara high-risk cases flagged
- Prioriterad efter risk score

Resultat:

- Flagged cases: 3
- Percent flagged: 0.15%

Tolkning:

- **Liknande resultat som testdata**
- **Vid samma threshold för test och ny data reagerar modellen likvärdigt**
- **Flaggar få men flaggar säkert**

Risker · Begränsningar · Nästa Steg

Risker i Produktion

- Modellen tränad på historisk data – kan missa nya bedrägerimönster (drift)
- Låg Recall: 97% av bedrägerier flaggas INTE
- Få testobservationer → osäker precision på testdata (5 flaggade)

Begränsningar

- Threshold-analys på träningsdata → något optimistiska siffror
- Smalt C-intervall i GridSearch (medvetet coarse-to-fine)
- Klassbalansen 10% påverkar alla metrics

Nästa Steg/Rekommendation

- Samla mer data
- Lägg till features
- Monitorera modellprestanda löpande (concept drift)
- Testa GradientBoosting för bättre Recall
- Bygg policy: vad händer när någon flaggas?